

ON TIME AI: Predecir retrasos antes de que ocurran

Irene Díaz

Proyecto de Machine Learning - Bootcamp Data Science - The Bridge
Mayo 2026



El problema

6 de cada 10 paquetes llegan tarde


Una empresa de e-commerce gestiona miles de envíos diarios

El 59,7% llegan tarde al cliente

Retraso no gestionado = reclamación, reseña negativa o pérdida del cliente

⚠ El problema no es puntual, es sistémico

¿Y si pudiéramos saber qué paquetes van a llegar tarde **ANTES** de que salgan del almacén?



Dataset

11.000 REGISTROS Y 12 VARIABLES

Target: Reached.on.Time_Y.N

0 = a tiempo | 1 = retraso

 La métrica prioritaria es el **RECALL** para detectar el máximo número de retrasos reales antes de que ocurran

Peso del paquete

Variable continua clave con comportamiento contraintuitivo

Descuento aplicado

Factor de riesgo número uno en todas las metodologías

Modo de envío

Barco, avión o por carretera tienen impactos muy distintos

Coste del producto, bloque del almacén...

Variables de contexto con capacidad predictiva

¿Qué encontramos en el EDA?



Hallazgo 1 — El efecto del descuento


A partir del **15% de descuento**, ningún envío llega a tiempo → Las campañas promocionales colapsan la logística

Hallazgo 2 — El peso del paquete

Los paquetes **ligeros (1–2 kg)** se retrasan **más**. Los pesados (4–6 kg) llegan mejor → Resultado contraintuitivo


Hallazgo 3 — El barco, el modo más problemático

Concentra el mayor volumen de retrasos, tanto en valor absoluto como en proporción sobre el total de envíos



Preprocesamiento

Dataset limpio: sin nulos ni duplicados → Directos a fase de transformación



Modelado supervisado y sus métricas clave

Un retraso no detectado = cliente que reclama sin haber recibido ninguna atención proactiva

Métricas:

Accuracy

Precision

F1-Score

Recall

ROC-AUC

Modelos:


Regresión Logística

Árbol de decisión

Random forest

XGBoost

KNN



Los ajustes que lo cambiaron todo

XGBoost tenía un Recall inicial del 47%

Primer ajuste: parámetro: `scale_pos_weight`

Cálculo incorrecto

negativos/positivos = **0,68**
El modelo priorizaba los envíos puntuales

Cálculo correcto

positivos/negativos = **1,48**
El modelo prioriza detectar retrasos

Resultado

El Recall pasó del **47%** al **91,6%**

Un solo parámetro, 44 puntos de diferencia

Segundo ajuste: parámetro `learning_rate`

Valor inicial

`learning_rate` = **0,1**
Cada árbol corrige el error en pasos grandes

Valor óptimo (GridSearchCV)

`learning_rate` = **0,05**
Corrige el error de forma más precisa y conservadora

Resultado

El Recall pasó del **91,6%** al **98%**

Otro parámetro que lo sube más de 6 puntos



Modelo ganador: XGBoost

Accuracy 59,8% · Precision 60% · **Recall 98%** · F1 74,4% · ROC-AUC 0,756

Clustering

K-Means: K=3 elegido por Método del Codo + Índice de Silhouette (0.2386)

Búsqueda del K óptimo



Clustering

Mismo patrón que el EDA y modelos supervisados: los retrasos no son aleatorios, se agrupan en perfiles de envío identificables



Cluster 0

99.5% de retraso · 20.9% de envíos

Descuento alto (media 40%)



Cluster 1

47.9% de retraso · 55.4% de envíos

Paquete pesado (media 4.801g)




Cluster 2

52.3% de retraso · 23.7% de envíos


Cliente fidelizado

Resultados del Clustering K-Means (K=3)

Tasa de Retraso por Cluster



Distribución de Envíos por Cluster



Impacto de negocio

De cada 100 retrasos reales, 98 son detectados antes de que ocurran

1.287

Clientes alertados

Reciben cupón preventivo (VERDADEROS POSITIVOS)

26


Retrasos no detectados

Falsos negativos — el coste real a minimizar

859

Cupones de más

Falsos positivos — coste asumible y predecible



✅ Un cupón enviado de más sorprende positivamente. Un cliente que reclama sin atención es un daño de reputación

Conclusiones

→ Los retrasos son anticipables

No son aleatorios: tienen causas identificables confirmadas por tres metodologías independientes

→ El descuento alto es el factor de riesgo nº 1

Confirmado por EDA, modelos supervisados y clustering

→ Alinear el modelo con el negocio es clave

Un parámetro bien calibrado vale tanto como elegir el algoritmo correcto.

Próximos pasos

01

Enriquecer el modelo

Añadir la variable Cluster como feature al modelo supervisado

02

Datos externos

Clima, calendario promocional y capacidad del almacén

03

Umbral de decisión

Calibrar el umbral por debajo del 50% según el coste real del cupón vs. el daño de reputación por retraso no detectado

Demo: On-Time AI

Aplicación interactiva desarrollada con Streamlit: mlshipping-ontimeai.streamlit.app

Predicción Individual


Introduce los datos de un envío y predice si llegará tarde

Carga Masiva

Sube un CSV y descarga las predicciones para todos los envíos

Análisis

Visualización de los hallazgos clave del proyecto



MILESKEER!

Irene Díaz

Proyecto de Machine Learning - Bootcamp Data Science - The Bridge

Mayo 2026